



Documentación, Diagnóstico, Correcciones y Próximos Pasos en JATS XML

Parseo automatizado de documentos DOCX → JATS XML (Front · Body · Back) | Universidad Nacional de Lanús

1. Visión general del estándar JATS XML

JATS XML (Journal Article Tag Suite, NISO Z39.96) es el estándar internacional utilizado para representar y estructurar la literatura científica digital. Todo documento JATS válido se organiza en tres secciones jerárquicas principales:

- **<front>**: contiene los metadatos de la revista (journal-meta) y los metadatos específicos del artículo (article-meta): título, autores, afiliaciones, resumen y fechas de gestión editorial.
- **<body>**: alberga el cuerpo textual estructurado (introducción, metodología, resultados, tablas, figuras y discusión).
- **<back>**: contiene los elementos finales, como la lista de referencias bibliográficas (ref-list), anexos y notas al pie.

2. Estructura y etiquetas principales del elemento <front>

La sección <front> organiza la información bibliográfica mediante la siguiente estructura de etiquetas:

Etiqueta JATS	Descripción / propósito	Subetiquetas / contexto clave
<journal-meta>	Metadatos de la publicación seriada.	<journal-id>, <journal-title-group>, <issn>, <publisher>
<article-meta>	Contenedor principal de metadatos del artículo.	Identificadores, títulos, autores, historial y resúmenes.
<article-id>	Identificador único del artículo.	pub-id-type="doi", pub-id-type="publisher-id"
<title-group>	Título principal y sus traducciones.	<article-title>, <trans-title-group>
<contrib-group>	Contenedor de autores y colaboradores.	<contrib contrib-type="author">, <name>, <email>, <xref>
<aff>	Afiliación institucional de los autores.	<institution content-type="orgname">, <addr-line>, <city>, <country>
<history>	Ciclo de vida editorial del artículo.	date-type="received"/"rev-recd"/"accepted" (<day>, <month>, <year>)
<abstract>	Resumen ejecutivo del trabajo.	<p>, atributos de idioma (xml:lang="es"/"en")
<kwd-group>	Palabras clave.	<kwd> (clasificadas por atributo xml:lang)

Ejemplo de fragmento XML <front> conforme al estándar

```
<front>
  <journal-meta>
    <journal-id journal-id-type="publisher-id">RevistaSistemas</journal-id>
    <issn pub-type="epub">2545-8124</issn>
  </journal-meta>
  <article-meta>
    <article-id pub-id-type="doi">10.12345/rs.v1i1.100</article-id>
    <title-group>
      <article-title>Arquitectura de Parseo Automatico para Documentos JATS</article-title>
      <trans-title-group xml:lang="en">
```

```
    <trans-title>Automated Parsing Architecture for JATS Documents</trans-title>
  </trans-title-group>
</title-group>
<contrib-group>
  <contrib contrib-type="author">
    <name>
      <surname>Gonzalez</surname>
      <given-names>Juan</given-names>
    </name>
    <xref ref-type="aff" rid="aff1"/>
  </contrib>
</contrib-group>
<aff id="aff1">
  <institution content-type="orgname">Universidad Nacional de Lanus</institution>
  <city>Lanus</city>
  <country country="AR">Argentina</country>
</aff>
<history>
  <date date-type="received">
    <day>15</day><month>03</month><year>2025</year>
  </date>
  <date date-type="accepted">
    <day>10</day><month>05</month><year>2025</year>
  </date>
</history>
<abstract xml:lang="es">
  <p>Este articulo analiza las estrategias de analisis sintactico...</p>
</abstract>
<kwd-group xml:lang="es">
  <kwd>JATS XML</kwd>
  <kwd>Ingesta de datos</kwd>
</kwd-group>
</article-meta>
</front>
```

3. Diagnóstico de fallas y correcciones aplicadas

Se listan los problemas detectados en el parser DOCX → JATS XML junto con la corrección puntual aplicada sobre el archivo, evitando repetir la misma observación en distintas secciones del informe.

Problema detectado	Causa raíz	Corrección aplicada
Nodo <history> ausente o incompleto	Regex rígidas que asumen un formato fijo (ej. "Recibido: 12 oct 2023"); variaciones de espacios o puntuación hacen que la fecha se ignore.	Se ajustaron los metadatos del <article> y se declaró correctamente dtd-version="1.1" y specific-use="sps-1.9" para garantizar el marcado válido del historial editorial.
Afiliaciones sin etiquetas semánticas	El patrón de extracción depende de comas como delimitador estricto; al faltar una coma, código postal o punto final, toda la cadena queda como texto plano dentro de <aff>.	Se limpiaron las redundancias en <bio> (duplicaba títulos académicos y correos) y se normalizaron los nombres institucionales dentro de <institution content-type="orgname">.
Formato inline (negritas, cursivas, enlaces) desacoplado	La eliminación manual de caracteres decorativos (':' o espacios) sobre nodos secundarios sin actualizar el contenedor principal rompe el renderizado de <ext-link> y otros estilos.	Se depuraron espacios finales en títulos (ej. "RESUMEN ") y dos puntos innecesarios en palabras clave (ej. "Keywords:"); restaurando la coherencia del marcado inline.
Excepciones por subcadenas vacías (IndexOutOfBounds / NullPointerException)	La normalización de meses recorta cadenas fijas sin validar coincidencias vacías o nulas, interrumpiendo el proceso de forma abrupta.	Corrección puntual en el módulo de normalización de fechas; pendiente de blindaje sistemático (ver sección 4).
Tablas e imágenes con estilos embebidos	Inyección de atributos CSS inline en celdas <th>/<td> (style="background-color:...") y rutas de <graphic> sin validar.	Se removieron los atributos CSS inline, delegando el diseño a la hoja de estilos XSLT/CSS del visualizador, y se validaron las rutas en <graphic xlink:href="...">.
Referencias bibliográficas truncadas	Desajuste entre los nodos reales de <ref-list> y la métrica declarada en el encabezado (<ref-count count="74"/>).	Se corrigió el truncamiento para alinear la cantidad real de referencias con el conteo declarado.

4. Próximos pasos para robustecer el parser

Recomendaciones estructurales para prevenir de raíz los problemas ya diagnosticados, en lugar de seguir corrigiéndolos caso por caso:

- **Tokenización léxica en lugar de regex rígidas:** reemplazar las expresiones regulares estrictas por un parser léxico flexible para capturar fechas de <history> y datos de ubicación geográfica en <aff>, sin depender de un formato exacto de puntuación o espaciado.
- **Normalización previa de cadenas (sanitizing):** aplicar una fase de limpieza que elimine espacios múltiples, caracteres invisibles y signos de puntuación al inicio/final antes de clasificar cada línea del documento fuente.
- **Manejo seguro de nulos y subcadenas:** incorporar comprobaciones de longitud previas y valores por defecto (getOrDefault) al normalizar meses u otros campos, para eliminar de raíz las excepciones por subcadenas vacías detectadas en la sección anterior.
- **Validación de esquema post-generación:** integrar una etapa automatizada de validación contra el DTD/XSD oficial de JATS/SciELO antes del almacenamiento final o el envío al sistema OJS, para detectar cualquier regresión antes de que llegue a producción.